École Nationale de la Statistique et de l'Analyse Économique

Analyste Statisticien 3E Année (AS3) · Deep Learning · 2025–2026

U-Net

Fondements Théoriques, Mathématiques et Revue de Littérature

Segmentation Sémantique par Réseaux de Neurones Convolutifs à Architecture Encodeur-Décodeur

Document de référence académique · Formules complètes · Fondements mathématiques

Convolution · Segmentation · Skip Connections · Fonctions de perte · Variantes

Groupe Deep Learning — Auteurs

- Ndeye Khar **SALL**
- Kouami Emmanuel **DOSSEKOU**
- Awa **GUEYE**
- Fatou Soumaya **WADE**

Résumé

U-Net est une architecture de réseau de neurones convolutifs introduite en 2015 par Ronneberger, Fischer et Brox, initialement conçue pour la segmentation d'images biomédicales. Elle repose sur un principe d'encodeur-décodeur symétrique enrichi par des *skip connections* qui préservent les informations spatiales fines à travers les niveaux de résolution. Ce document propose une revue exhaustive des fondements théoriques et mathématiques sous-jacents à U-Net : opérations de convolution, pooling, normalisation par lots, fonctions d'activation, fonctions de perte (cross-entropie, Dice, IoU), rétropropagation du gradient, ainsi que les principales variantes architecturales (Attention U-Net, U-Net++, 3D U-Net, Swin-UNet).

Opérations	Architecture	Fonctions	Variantes
Conv 2D	Enc.–Déc.	Dice+CE	6+

Contents

Résumé **1**

1 Contexte et Problématique de la Segmentation d'Images **5**

1.1 Taxonomie des tâches de vision par ordinateur 5

1.2 Enjeux mathématiques de la segmentation pixel-à-pixel 6

1.3 Bref historique de la segmentation par apprentissage 7

2 Fondements Mathématiques des Réseaux de Neurones Convolutifs **8**

2.1 La convolution discrète 2D 8

2.1.1 Définition et formulation 8

2.1.2 Extension multi-canaux 8

2.1.3 Propriétés fondamentales 9

2.2 Fonctions d'activation 9

2.2.1 ReLU et ses variantes 10

2.2.2 Softmax pour la classification multiclasse 10

2.3 Opérations de sous-échantillonnage 10

2.3.1 Max-pooling 11

2.3.2 Average-pooling et global average pooling 11

2.4 Normalisation par lots (Batch Normalization) 11

2.5 La rétropropagation du gradient. 12

2.5.1 Règle de la chaîne et graphe de calcul 12

2.5.2 Problème du gradient qui disparaît 13

2.5.3 Mise à jour des paramètres : Adam 13

3 Architecture U-Net : Théorie et Formulation **14**

3.1 Architecture originale (Ronneberger et al., 2015) 14

3.1.1 Diagramme architectural 15

3.1.2 Bloc convolutif de base . . . 15
3.2 L'encodeur : chemin contractant . . . 16
3.3 Le goulot d'étranglement (Bottleneck) . . . 16
3.4 Le décodeur : chemin expansif . . . 16
3.4.1 Transposed Convolution (UpConv) . . . 16
3.4.2 Skip connections et concaténation . . . 17
3.5 Couche de sortie . . . 17
3.6 Complexité paramétrique . . . 18

4 Fonctions de Perte pour la Segmentation 19
4.1 Vue d'ensemble . . . 19
4.2 Entropie croisée (Cross-Entropy) . . . 19
4.2.1 Formulation générale . . . 19
4.2.2 Weighted Cross-Entropy . . . 19
4.3 Perte de Dice . . . 20
4.3.1 Coefficient de Dice . . . 20
4.4 Perte IoU (Intersection over Union) . . . 21
4.5 Focal Loss . . . 21
4.6 Pertes composées . . . 21

5 Métriques d'Évaluation 23
5.1 Métriques pixel-à-pixel . . . 23
5.2 Hausdorff Distance et précision des contours . . . 24

6 Stratégies d'Entraînement et Régularisation 25
6.1 Augmentation de données . . . 25
6.2 Dropout et régularisation . . . 26
6.3 Planification du taux d'apprentissage . . . 26
6.4 Transfert d'apprentissage . . . 27

7 Variantes et Extensions de U-Net 28
7.1 Attention U-Net (Oktay et al., 2018) . . . 28
7.2 U-Net++ (Zhou et al., 2019) . . . 28

7.3 3D U-Net (Çiçek et al., 2016) 29
7.4 Swin-UNet (Cao et al., 2021) 29
7.5 Résumé comparatif des variantes 30

8 Applications et État de l'Art 31

8.1 Segmentation médicale 31
8.2 Au-delà du médical : domaines d'application 31

9 Fondements Théoriques Profonds 33

9.1 Connexion avec la théorie de l'information 33
9.1.1 Entropie croisée comme divergence KL 33
9.2 Lien avec les auto-encodeurs variationnels. 33
9.3 Théorème d'approximation universel et profondeur 34
9.4 Interprétabilité : Grad-CAM en segmentation 34

Conclusion et Perspectives 35

Références Bibliographiques 36

1

Contexte et Problématique de la Segmentation d'Images

★ Définition fondamentale

La **segmentation sémantique** est la tâche consistant à attribuer une étiquette de classe à *chaque pixel* d'une image. Formellement, étant donné une image $I \in \mathbb{R}^{H \times W \times C}$, on cherche une fonction $f_\theta : \mathbb{R}^{H \times W \times C} \to \{1, \ldots, K\}^{H \times W}$ paramétrée par θ qui maximise la concordance avec une carte de segmentation de vérité terrain $Y \in \{1, \ldots, K\}^{H \times W}$.

1.1 Taxonomie des tâches de vision par ordinateur

La segmentation d'images se distingue fondamentalement des autres tâches de vision par ordinateur par la granularité de sa prédiction. Là où la classification produit un unique vecteur de probabilités pour une image entière, la segmentation exige une décision indépendante pour chacun des $H \times W$ pixels.

Table 1.1. Taxonomie des tâches de vision par ordinateur

Tâche	Sortie	Granularité	Exemple
Classification	Vecteur $\in \mathbb{R}^K$	Image entière	ResNet, VGG
Détection	Boîtes englobantes + labels	Région	YOLO, Faster R-CNN
Segmentation sémantique	Carte $H \times W$ (classes)	Pixel	U-Net, FCN
Segmentation d'instances	Carte + identité	Pixel + instance	Mask R-CNN
Segmentation panoptique	Classes + instances	Pixel complet	Panoptic FPN

1.2 Enjeux mathématiques de la segmentation pixel-à-pixel

La difficulté centrale réside dans la nature du problème d'optimisation. Pour une image de résolution $H \times W = 512 \times 512$, la sortie comporte 262 144 prédictions interdépendantes. Le modèle doit simultanément :

1. **Capturer le contexte global** : comprendre la sémantique de la scène à grande échelle (champ récepteur large).
2. **Préserver la précision spatiale** : localiser les frontières entre classes au niveau du pixel (résolution fine).
3. **Gérer les déséquilibres de classes** : dans les images médicales, la région d'intérêt peut représenter moins de 1 % des pixels.

Ces trois contraintes sont en tension fondamentale : l'augmentation du champ

récepteur (via la profondeur du réseau ou le max-pooling) dégrade mécaniquement la résolution spatiale. C'est précisément ce compromis que U-Net résout par les *skip connections*.

1.3 Bref historique de la segmentation par apprentissage

Table 1.2. Évolution historique des architectures de segmentation

Année	Architecture	Innovation principale
2014	**FCN**	Première architecture fully convolutional, upsampling appris
2015	**U-Net**	Skip connections, encodeur-décodeur symétrique
2015	**SegNet**	Encoder-decoder avec mémorisation des indices de pooling
2016	**DeepLab v1**	Convolutions atrous (dilatées) pour le champ récepteur
2017	**PSPNet**	Pyramid Pooling Module, contexte multi-échelles
2018	**DeepLab v3+**	Atrous Spatial Pyramid Pooling + décodeur léger
2018	**Attention U-Net**	Mécanisme d'attention dans les skip connections
2019	**U-Net++**	Skip connections denses, architecture en nid d'abeilles
2021	**Swin-UNet**	Transformers hiérarchiques, self-attention globale
2022	**nnU-Net**	Auto-configuration adaptative, état de l'art médical

2

Fondements Mathématiques des Réseaux de Neurones Convolutifs

2.1 La convolution discrète 2D

§ 2.1.1 Définition et formulation

L'opération centrale des CNN est la **convolution discrète 2D**. Soit $X \in \mathbb{R}^{H \times W}$ une carte d'activation (un canal), et $W \in \mathbb{R}^{k \times k}$ un filtre (noyau) de taille $k \times k$. La convolution produit une carte de sortie $Z \in \mathbb{R}^{H' \times W'}$:

Convolution discrète 2D

$$Z[i,j] = (X * W)[i,j] = \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} X[i \cdot s + m,\ j \cdot s + n] \cdot W[m,n] + b \tag{2.1}$$

où s est le *stride*, $b \in \mathbb{R}$ le biais, et $H' = \lfloor (H - k + 2p)/s \rfloor + 1$, $W' = \lfloor (W - k + 2p)/s \rfloor + 1$ avec p le *padding*.

§ 2.1.2 Extension multi-canaux

En pratique, les images et cartes d'activation ont C_{in} canaux. Un filtre de convolution est alors $W \in \mathbb{R}^{C_{\text{out}} \times C_{\text{in}} \times k \times k}$. La carte de sortie $Z \in \mathbb{R}^{C_{\text{out}} \times H' \times W'}$ vérifie :

Convolution multi-canaux

$$Z[c_{\text{out}}, i, j] = \sum_{c=1}^{C_{\text{in}}} \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} W[c_{\text{out}}, c, m, n] \cdot X[c, i \cdot s + m, j \cdot s + n] + b[c_{\text{out}}] \quad (2.2)$$

Le nombre total de paramètres du filtre est $C_{\text{out}} \times C_{\text{in}} \times k^2$.

§ 2.1.3 Propriétés fondamentales

Équivariance par translation. La convolution satisfait : $f(T_\Delta(X)) = T_\Delta(f(X))$ où T_Δ est une translation de vecteur Δ. Cette propriété est fondamentale : un filtre appris pour détecter un bord vertical en position (i, j) le détectera en toute position de l'image.

Champ récepteur. Pour une pile de L couches convolutives de taille k avec stride $s = 1$, le champ récepteur d'une unité de la couche L couvre une région de taille :

$$r_L = 1 + L(k - 1) \quad (2.3)$$

Avec max-pooling de facteur p, il est multiplié par p à chaque niveau.

2.2 Fonctions d'activation

§ 2.2.1 ReLU et ses variantes

Fonctions d'activation

$$\mathrm{ReLU}(x) = \max(0, x) = x \cdot \mathbf{1}_{x>0} \tag{2.4}$$

$$\text{Leaky ReLU}(x) = \begin{cases} x & x > 0 \\ \alpha x & x \leq 0 \end{cases}, \quad \alpha \ll 1 \tag{2.5}$$

$$\mathrm{ELU}(x) = \begin{cases} x & x > 0 \\ \alpha(e^x - 1) & x \leq 0 \end{cases} \tag{2.6}$$

$$\mathrm{GELU}(x) = x \cdot \Phi(x) \approx x \cdot \sigma(1{,}702\, x) \tag{2.7}$$

où Φ est la CDF de la loi normale standard.

ReLU résout le problème du *vanishing gradient* présent avec tanh et σ : sa dérivée est $\frac{d}{dx}\mathrm{ReLU}(x) = \mathbf{1}_{x>0}$, ce qui permet une rétropropagation du gradient sans atténuation pour $x > 0$.

§ 2.2.2 Softmax pour la classification multiclasse

En segmentation multi-classes, la couche de sortie applique la fonction *softmax* pixel par pixel. Pour le pixel (i, j) et la classe c :

Softmax pixel-à-pixel

$$\hat{p}_{ij}^{(c)} = \mathrm{softmax}(z_{ij})_c = \frac{\exp(z_{ij}^{(c)})}{\sum_{k=1}^{K} \exp(z_{ij}^{(k)})} \tag{2.8}$$

avec $z_{ij} \in \mathbb{R}^K$ le vecteur logit du pixel (i, j). On vérifie : $\sum_{c=1}^{K} \hat{p}_{ij}^{(c)} = 1$ et $\hat{p}_{ij}^{(c)} \in (0, 1)$.

2.3 Opérations de sous-échantillonnage

§ 2.3.1 Max-pooling

Le max-pooling réduit la résolution spatiale d'un facteur s en sélectionnant le maximum dans chaque fenêtre $k \times k$:

Max-pooling 2D

$$Z[i,j] = \mathrm{MaxPool}(X)[i,j] = \max_{0 \le m < k,\ 0 \le n < k} X[i \cdot s + m,\ j \cdot s + n] \tag{2.9}$$

Le max-pooling **ne possède pas de paramètres apprenables**. Sa rétropropagation achemine le gradient uniquement vers le neurone qui a réalisé le maximum lors de la passe avant (*switch variable*).

§ 2.3.2 Average-pooling et global average pooling

$$\mathrm{AvgPool}(X)[i,j] = \frac{1}{k^2} \sum_{m=0}^{k-1} \sum_{n=0}^{k-1} X[i \cdot s + m,\ j \cdot s + n] \tag{2.10}$$

Le **Global Average Pooling** (GAP) réduit une carte $H \times W$ à un scalaire : $\mathrm{GAP}(X) = \frac{1}{HW} \sum_{i,j} X[i,j]$.

2.4 Normalisation par lots (Batch Normalization)

La normalisation par lots (Ioffe & Szegedy, 2015) stabilise l'entraînement en normalisant les activations par mini-batch. Pour une activation x dans un batch $\mathcal{B} = \{x_1, \ldots, x_m\}$:

Batch Normalization

$$\mu_{\mathcal{B}} = \frac{1}{m}\sum_{i=1}^{m} x_i \qquad \text{(moyenne)} \tag{2.11}$$

$$\sigma_{\mathcal{B}}^2 = \frac{1}{m}\sum_{i=1}^{m}(x_i - \mu_{\mathcal{B}})^2 \qquad \text{(variance)} \tag{2.12}$$

$$\hat{x}_i = \frac{x_i - \mu_{\mathcal{B}}}{\sqrt{\sigma_{\mathcal{B}}^2 + \varepsilon}} \qquad \text{(normalisation)} \tag{2.13}$$

$$y_i = \gamma\,\hat{x}_i + \beta \qquad \text{(mise à l'échelle apprenable, } \gamma, \beta \in \mathbb{R}) \tag{2.14}$$

où $\varepsilon > 0$ est un terme de stabilité numérique (typiquement 10^{-5}).

Effet régularisant. La BN agit comme un régularisateur implicite en introduisant du bruit stochastique lié aux statistiques du mini-batch, réduisant le besoin de dropout dans les couches convolutives.

2.5 La rétropropagation du gradient

§ 2.5.1 Règle de la chaîne et graphe de calcul

L'entraînement minimise une fonction de perte $\mathcal{L}(\theta)$ par descente de gradient stochastique. Pour une couche de paramètres $\theta^{(l)}$, le gradient est obtenu par la **règle de la chaîne** :

Rétropropagation

$$\frac{\partial \mathcal{L}}{\partial \theta^{(l)}} = \frac{\partial \mathcal{L}}{\partial z^{(l)}} \cdot \frac{\partial z^{(l)}}{\partial \theta^{(l)}} = \delta^{(l)} \cdot \frac{\partial z^{(l)}}{\partial \theta^{(l)}} \tag{2.15}$$

où $\delta^{(l)} = \frac{\partial \mathcal{L}}{\partial z^{(l)}}$ est le signal d'erreur rétropropagé. Pour une couche dense :

$$\delta^{(l)} = \left(W^{(l+1)}\right)^{\top} \delta^{(l+1)} \odot \varphi'\left(z^{(l)}\right) \tag{2.16}$$

où $\odot$ désigne le produit élément par élément (Hadamard) et φ' la dérivée de la fonction d'activation.

§ 2.5.2 Problème du gradient qui disparaît

Pour un réseau profond de L couches activées par sigmoid : $\sigma'(x) = \sigma(x)(1 - \sigma(x)) \leq \frac{1}{4}$, donc :

$$\left\|\delta^{(1)}\right\| \leq \left(\frac{1}{4}\right)^{L-1} \|W\|^{L-1} \left\|\delta^{(L)}\right\| \xrightarrow[L\to\infty]{} 0 \tag{2.17}$$

C'est pourquoi ReLU ($\varphi'(x) = \mathbf{1}_{x>0}$) et les connexions résiduelles sont fondamentales dans les architectures profondes.

§ 2.5.3 Mise à jour des paramètres : Adam

L'optimiseur Adam (Kingma & Ba, 2015) adapte le taux d'apprentissage par paramètre :

Optimiseur Adam

$$m_t = \beta_1 m_{t-1} + (1-\beta_1) g_t \qquad (1^{\text{er}} \text{ moment}) \tag{2.18}$$

$$v_t = \beta_2 v_{t-1} + (1-\beta_2) g_t^2 \qquad (2^{\text{e}} \text{ moment}) \tag{2.19}$$

$$\hat{m}_t = \frac{m_t}{1-\beta_1^t}, \quad \hat{v}_t = \frac{v_t}{1-\beta_2^t} \qquad \text{(correction du biais)} \tag{2.20}$$

$$\theta_t = \theta_{t-1} - \frac{\eta}{\sqrt{\hat{v}_t} + \varepsilon} \hat{m}_t \tag{2.21}$$

Valeurs typiques : $\beta_1 = 0{,}9$, $\beta_2 = 0{,}999$, $\varepsilon = 10^{-8}$, $\eta = 10^{-3}$.

3

Architecture U-Net : Théorie et Formulation

3.1 Architecture originale (Ronneberger et al., 2015)

U-NET tire son nom de la forme en U de son architecture. Elle se compose de deux chemins symétriques : un **chemin contractant** (encodeur) qui extrait des représentations sémantiques de plus en plus abstraites à résolution décroissante, et un **chemin expansif** (décodeur) qui reconstruit progressivement la résolution spatiale tout en intégrant les informations contextuelles via les *skip connections*.

§ 3.1.1 Diagramme architectural

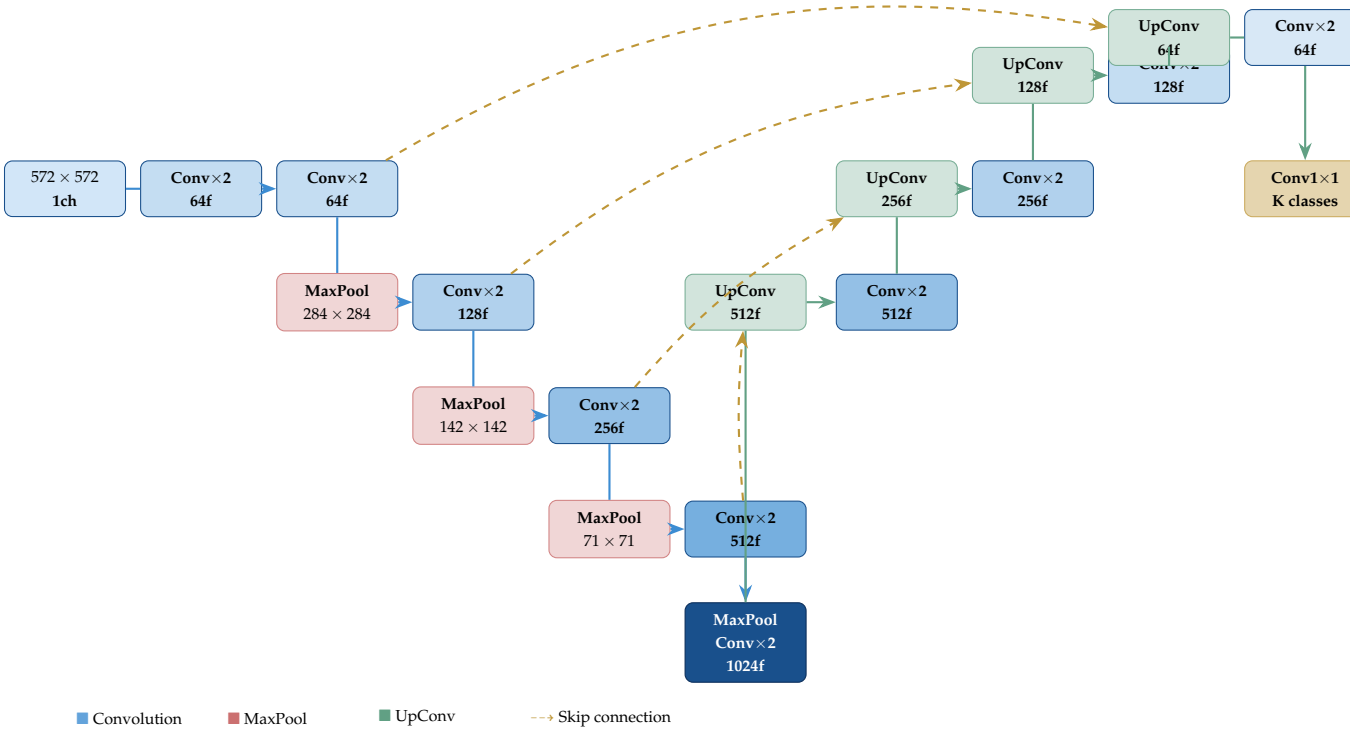

Figure 3.1. Architecture U-Net originale (Ronneberger et al., 2015) — schéma simplifié

§ 3.1.2 Bloc convolutif de base

Chaque bloc élémentaire de U-Net applique deux convolutions 3×3 successives, chacune suivie d'une Batch Normalization et d'une ReLU :

Bloc convolutif double (Double Conv Block)

$$Z_1 = \mathrm{ReLU}(\mathrm{BN}(W_1 * X + b_1)) \in \mathbb{R}^{C_{\text{out}} \times H \times W} \tag{3.1}$$

$$Z_2 = \mathrm{ReLU}(\mathrm{BN}(W_2 * Z_1 + b_2)) \in \mathbb{R}^{C_{\text{out}} \times H \times W} \tag{3.2}$$

avec $W_1, W_2 \in \mathbb{R}^{C_{\text{out}} \times C_{\text{in}} \times 3 \times 3}$. Dans l'implémentation originale, le padding est nul (`valid`), ce qui réduit légèrement la résolution : $H_{\text{out}} = H - 4$. Dans les variantes modernes, on utilise `same` pour conserver H.

3.2 L'encodeur : chemin contractant

L'encodeur comprend N niveaux. À chaque niveau ℓ ($\ell = 1, \ldots, N$) :

Encodeur — Niveau ℓ

$$F_\ell = \text{DoubleConv}(F_{\ell-1}) \in \mathbb{R}^{2^{\ell+5} \times \frac{H}{2^{\ell-1}} \times \frac{W}{2^{\ell-1}}} \quad \text{(extraction de caractéristiques)} \tag{3.3}$$

$$D_\ell = \text{MaxPool}_{2\times 2}(F_\ell) \in \mathbb{R}^{2^{\ell+5} \times \frac{H}{2^\ell} \times \frac{W}{2^\ell}} \quad \text{(sous-échantillonnage)} \tag{3.4}$$

Le nombre de filtres **double** à chaque niveau : $64 \to 128 \to 256 \to 512 \to 1024$.

Cette progression géométrique est motivée par le **théorème de compression de l'information** : réduire la résolution spatiale d'un facteur 2 en doublant le nombre de canaux maintient approximativement la capacité d'information du tenseur.

3.3 Le goulot d'étranglement (Bottleneck)

$$B = \text{DoubleConv}(D_N) \in \mathbb{R}^{1024 \times \frac{H}{2^N} \times \frac{W}{2^N}} \tag{3.5}$$

Le bottleneck est la représentation la plus compressée et la plus sémantique de l'image. Il force le réseau à encoder l'information pertinente dans un espace de faible dimension spatiale mais de haute dimension de caractéristiques.

3.4 Le décodeur : chemin expansif

§ 3.4.1 Transposed Convolution (UpConv)

Le sur-échantillonnage appris est réalisé par la **convolution transposée** (aussi appelée déconvolution ou fractionally-strided convolution) :

Convolution transposée 2D

$$Z[i,j] = \sum_{m,n} X\left[\left\lfloor \frac{i-m}{s} \right\rfloor, \left\lfloor \frac{j-n}{s} \right\rfloor\right] \cdot W[m,n] \cdot \mathbf{1}_{s|(i-m)} \cdot \mathbf{1}_{s|(j-n)} \tag{3.6}$$

La sortie a pour dimensions $H_{\text{out}} = s(H_{\text{in}} - 1) + k - 2p$, ce qui permet de doubler la résolution spatiale ($s = 2, k = 2$).

§ 3.4.2 Skip connections et concaténation

C'est l'innovation centrale de U-Net. Avant d'appliquer le bloc convolutif, les cartes de caractéristiques de l'encodeur F_ℓ sont **concaténées** avec les cartes sur-échantillonnées du décodeur :

Skip Connection — Niveau ℓ du décodeur

$$U_\ell = \text{UpConv}_{2\times 2}(G_{\ell+1}) \in \mathbb{R}^{2^{\ell+4} \times \frac{H}{2^{\ell-1}} \times \frac{W}{2^{\ell-1}}} \tag{3.7}$$

$$S_\ell = \text{CenterCrop}(F_\ell, U_\ell) \qquad \text{(alignement spatial si padding=valid)} \tag{3.8}$$

$$\tilde{G}_\ell = [U_\ell \parallel S_\ell] \in \mathbb{R}^{2\cdot 2^{\ell+4} \times \frac{H}{2^{\ell-1}} \times \frac{W}{2^{\ell-1}}} \qquad \text{(concaténation sur l'axe des canaux)} \tag{3.9}$$

$$G_\ell = \text{DoubleConv}(\tilde{G}_\ell) \tag{3.10}$$

où $[\cdot \parallel \cdot]$ désigne la concaténation sur la dimension des canaux.

Pourquoi les skip connections fonctionnent-elles ? Les gradients peuvent circuler directement de la sortie vers les couches peu profondes via les skip connections, atténuant le vanishing gradient : $\frac{\partial \mathcal{L}}{\partial F_\ell}$ reçoit deux contributions : une via le chemin normal du décodeur, et une directement depuis la perte de segmentation.

3.5 Couche de sortie

La couche finale applique une convolution 1×1 qui projette les C_{out} canaux du dernier bloc sur K cartes de logits :

$$\hat{Y}^{(c)}[i,j] = \text{Conv}_{1\times 1}(G_1)^{(c)}[i,j], \quad c = 1, \ldots, K \tag{3.11}$$

Suivie d'un softmax pixel-à-pixel (segmentation multi-classes) ou d'une sigmoïde (segmentation binaire) :

$$\hat{p}^{(c)}[i,j] = \begin{cases} \sigma\left(\hat{Y}^{(1)}[i,j]\right) & K = 2 \text{ (binaire)} \\ \operatorname{softmax}\left(\hat{Y}[i,j]\right)_c & K > 2 \text{ (multi-classes)} \end{cases} \tag{3.12}$$

3.6 Complexité paramétrique

Table 3.1. Nombre de paramètres par niveau dans U-Net original

Niveau	C_{in}	C_{out}	Opérat	Paramètres
0	1	64	2× Conv 3×3	$2(1 \cdot 64 \cdot 9 + 64) + 2(64 \cdot 64 \cdot 9 + 64) = 74\,368$
1	64	128	2× Conv 3×3	$\approx 221\,440$
2	128	256	2× Conv 3×3	$\approx 885\,248$
3	256	512	2× Conv 3×3	$\approx 3\,539\,456$
Bottleneck	512	1024	2× Conv 3×3	$\approx 14\,157\,824$
Décodeur	—	—	Symétrique	$\approx 18\,000\,000$
Total				$\approx$ **31 000 000**

4

Fonctions de Perte pour la Segmentation

4.1 Vue d'ensemble

Le choix de la fonction de perte est critique en segmentation, notamment face aux **déséquilibres de classes** omniprésents dans les images médicales. Plusieurs familles de pertes sont utilisées.

4.2 Entropie croisée (Cross-Entropy)

§ 4.2.1 Formulation générale

Pour un pixel (i, j) et une image $\mathcal{D} = \{(x_n, y_n)\}_{n=1}^{N}$:

Entropie croisée pixel-à-pixel

$$\mathcal{L}_{\text{CE}} = -\frac{1}{HW} \sum_{i=1}^{H} \sum_{j=1}^{W} \sum_{c=1}^{K} y_{ij}^{(c)} \log \hat{p}_{ij}^{(c)} \tag{4.1}$$

$$\text{(binaire) } \mathcal{L}_{\text{BCE}} = -\frac{1}{HW} \sum_{i,j} \Big[y_{ij} \log \hat{p}_{ij} + (1 - y_{ij}) \log(1 - \hat{p}_{ij}) \Big] \tag{4.2}$$

§ 4.2.2 Weighted Cross-Entropy

Pour corriger le déséquilibre de classes, on introduit un poids w_c inversement proportionnel à la fréquence de la classe :

$$\mathcal{L}_{\text{WCE}} = -\frac{1}{HW}\sum_{i,j}\sum_{c=1}^{K} w_c \cdot y_{ij}^{(c)} \log \hat{p}_{ij}^{(c)}, \quad w_c = \frac{1/f_c}{\sum_k 1/f_k} \tag{4.3}$$

où $f_c = |\{(i,j) : y_{ij}^{(c)} = 1\}|/(HW)$ est la fréquence de la classe c.

Dans l'article original de U-Net, les poids sont calculés selon une carte de distances aux frontières cellulaires :

Poids de bord (U-Net original)

$$w(x) = w_c(x) + w_0 \exp\left(-\frac{(d_1(x) + d_2(x))^2}{2\sigma^2}\right) \tag{4.4}$$

où $d_1(x), d_2(x)$ sont les distances aux deux cellules les plus proches, $w_0 = 10$, $\sigma = 5$ pixels.

4.3 Perte de Dice

§ 4.3.1 Coefficient de Dice

Le coefficient de Dice (ou F1-score au niveau pixel) mesure le recouvrement entre la prédiction $\hat{Y}$ et la vérité terrain Y :

Coefficient et perte de Dice

$$\text{Dice}(Y, \hat{Y}) = \frac{2\,|Y \cap \hat{Y}|}{|Y| + |\hat{Y}|} = \frac{2\sum_{i,j} y_{ij}\hat{p}_{ij}}{\sum_{i,j} y_{ij} + \sum_{i,j} \hat{p}_{ij}} \tag{4.5}$$

$$\mathcal{L}_{\text{Dice}} = 1 - \text{Dice}(Y, \hat{Y}) = 1 - \frac{2\sum_{i,j} y_{ij}\hat{p}_{ij} + \varepsilon}{\sum_{i,j} y_{ij} + \sum_{i,j} \hat{p}_{ij} + \varepsilon} \tag{4.6}$$

où $\varepsilon > 0$ (typiquement 10^{-6}) évite la division par zéro.

Avantage clé. La perte de Dice est **invariante au déséquilibre de classes** car elle normalise par la taille des ensembles : une classe rare avec une bonne prédiction contribue autant qu'une classe fréquente.

4.4 Perte IoU (Intersection over Union)

Perte IoU différentiable (Soft IoU)

$$\mathrm{IoU}(Y, \hat{Y}) = \frac{|Y \cap \hat{Y}|}{|Y \cup \hat{Y}|} = \frac{\sum_{i,j} y_{ij}\hat{p}_{ij}}{\sum_{i,j}(y_{ij} + \hat{p}_{ij} - y_{ij}\hat{p}_{ij})} \tag{4.7}$$

$$\mathcal{L}_{\mathrm{IoU}} = 1 - \mathrm{IoU}(Y, \hat{Y}) \tag{4.8}$$

Relation avec Dice : $\mathrm{Dice} = \frac{2\,\mathrm{IoU}}{1+\mathrm{IoU}}$, soit $\mathrm{IoU} = \frac{\mathrm{Dice}}{2-\mathrm{Dice}}$.

4.5 Focal Loss

Introduite par Lin et al. (2017) pour les détecteurs d'objets, la Focal Loss réduit la contribution des exemples faciles et concentre l'apprentissage sur les pixels difficiles :

Focal Loss

$$\mathcal{L}_{\mathrm{FL}} = -\frac{1}{HW}\sum_{i,j}\sum_{c=1}^{K} \alpha_c \left(1 - \hat{p}_{ij}^{(c)}\right)^{\gamma} y_{ij}^{(c)} \log \hat{p}_{ij}^{(c)} \tag{4.9}$$

où $\gamma > 0$ est le paramètre de focalisation (typiquement $\gamma = 2$) et α_c équilibre les classes. Pour $\gamma = 0$, on retrouve la WCE.

4.6 Pertes composées

En pratique, on combine plusieurs pertes pour tirer parti de leurs complémentarités :

Pertes composées

$$\mathcal{L}_{\text{DC+CE}} = \mathcal{L}_{\text{Dice}} + \lambda\, \mathcal{L}_{\text{CE}} \qquad (\lambda = 1 \text{ typiquement}) \tag{4.10}$$

$$\mathcal{L}_{\text{Tversky}} = 1 - \frac{\sum y\hat{p} + \varepsilon}{\sum y\hat{p} + \alpha \sum (1-y)\hat{p} + \beta \sum y(1-\hat{p}) + \varepsilon} \tag{4.11}$$

La Tversky Loss généralise Dice : $\alpha = \beta = 0{,}5$ redonne Dice. Pour $\alpha < \beta$, on pénalise davantage les faux négatifs (FN), utile pour les structures rares et petites.

5

Métriques d'Évaluation

5.1 Métriques pixel-à-pixel

Table 5.1. Métriques d'évaluation de la segmentation sémantique

Métrique	Formule	Intervalle
Accuracy pixel	$\frac{TP+TN}{TP+TN+FP+FN}$	$[0,1]$
Dice / F1	$\frac{2\,TP}{2\,TP+FP+FN}$	$[0,1]$
IoU / Jaccard	$\frac{TP}{TP+FP+FN}$	$[0,1]$
Précision	$\frac{TP}{TP+FP}$	$[0,1]$
Rappel / Sensibilité	$\frac{TP}{TP+FN}$	$[0,1]$
Spécificité	$\frac{TN}{TN+FP}$	$[0,1]$
Mean IoU (mIoU)	$\frac{1}{K}\sum_{c=1}^{K} \mathrm{IoU}_c$	$[0,1]$

5.2 Hausdorff Distance et précision des contours

Distance de Hausdorff (95e percentile)

$$d_H(A,B) = \max\left(\sup_{a\in A}\inf_{b\in B} d(a,b),\ \sup_{b\in B}\inf_{a\in A} d(a,b)\right) \tag{5.1}$$

$$\mathrm{HD}_{95} = 95^{e} \text{ percentile de } \{d(a,B)\}_{a\in A} \cup \{d(b,A)\}_{b\in B} \tag{5.2}$$

HD_{95} est plus robuste aux outliers que HD_{100}.

6

Stratégies d'Entraînement et Régularisation

6.1 Augmentation de données

L'AUGMENTATION de données est particulièrement critique en imagerie médicale où les jeux de données annotés sont rares et coûteux à constituer. Ronneberger et al. insistent sur les **déformations élastiques aléatoires** comme transformation clé :

Déformations élastiques (augmentation U-Net)

$$\Delta u(x,y) = \sum_{i,j} \alpha_{ij}\, G_\sigma(x - x_i, y - y_j) \qquad \text{(champ de déplacement)} \tag{6.1}$$

$$\tilde{I}(x,y) = I(x + \Delta u_x(x,y),\ y + \Delta u_y(x,y)) \qquad \text{(image déformée)} \tag{6.2}$$

où G_σ est un noyau gaussien de déviation σ, α_{ij} des amplitudes aléatoires $\sim \mathcal{U}(-1,1)$.

D'autres transformations classiques : rotations aléatoires $\theta \sim \mathcal{U}(-180,180)$, flips horizontaux/verticaux, zoom $z \sim \mathcal{U}(0{,}8, 1{,}2)$, ajustements de contraste, ajout de bruit gaussien.

6.2 Dropout et régularisation

Dropout stochastique

$$\tilde{h}_i = h_i \cdot \frac{r_i}{1-p}, \quad r_i \sim \text{Bernoulli}(1-p) \tag{6.3}$$

Durant l'inférence, le facteur $\frac{1}{1-p}$ est retiré (*inverted dropout*). Dans U-Net, le dropout est appliqué après les blocs convolutifs profonds (bottleneck).

MC Dropout (Gal & Ghahramani, 2016). En conservant le dropout actif à l'inférence et en effectuant T passes, on obtient une estimation bayésienne de l'incertitude de prédiction :

$$\bar{p}(y|x) \approx \frac{1}{T}\sum_{t=1}^{T} p_\theta^{(t)}(y|x), \quad \text{Var}(y) \approx \frac{1}{T}\sum_{t=1}^{T} \hat{p}_t^2 - \bar{p}^2 \tag{6.4}$$

6.3 Planification du taux d'apprentissage

Stratégie	Formule	Usage
Step decay	$\eta_t = \eta_0 \cdot \gamma^{\lfloor t/s \rfloor}$	Général
Cosine Annealing	$\eta_t = \eta_{\min} + \frac{1}{2}(\eta_0 - \eta_{\min})\left(1 + \cos\frac{\pi t}{T}\right)$	Fine-tuning
ReduceLROnPlateau	$\eta \leftarrow \eta \cdot \rho$ si pas d'amélioration pendant p epochs	Médical
Warm-up + Decay	$\eta_t = \eta_0 \cdot \min(t^{-0.5}, t \cdot w^{-1.5})$	Transformers

6.4 Transfert d'apprentissage

Principe du fine-tuning

L'encodeur de U-Net peut être initialisé avec les poids d'un réseau pré-entraîné sur ImageNet (ResNet, EfficientNet, etc.). Seul le décodeur est entraîné depuis zéro dans un premier temps, puis l'ensemble est fine-tuné avec un faible taux d'apprentissage : $\eta_{\text{enc}} = 0{,}1 \times \eta_{\text{dec}}$.

7

Variantes et Extensions de U-Net

7.1 Attention U-Net (Oktay et al., 2018)

ATTENTION U-NET introduit des **portes d'attention** (*attention gates*) dans les skip connections, permettant au décodeur de pondérer sélectivement les caractéristiques de l'encodeur en fonction de leur pertinence :

Mécanisme d'Attention Gate

$$q_g^l = W_g\, g + b_g \qquad \text{(signal d'attention venant du décodeur)} \tag{7.1}$$

$$q_x^l = W_x\, F_\ell + b_x \qquad \text{(features de l'encodeur)} \tag{7.2}$$

$$\alpha_\ell = \sigma\Big(W_\psi\,\Big(\mathrm{ReLU}(q_g^l + q_x^l)\Big) + b_\psi\Big) \in (0,1)^{H\times W} \tag{7.3}$$

$$\tilde{F}_\ell = \alpha_\ell \odot F_\ell \qquad \text{(features pondérées)} \tag{7.4}$$

où $\odot$ est le produit de Hadamard et α_ℓ est la **carte d'attention** spatiale apprise.

7.2 U-Net++ (Zhou et al., 2019)

U-Net++ remplace les skip connections directes par des **chemins intermédiaires denses**, formant un réseau en nid d'abeilles. Les nœuds $x^{i,j}$ sont définis récursivement :

U-Net++ — Nœuds intermédiaires

$$x^{i,j} = \begin{cases} \mathcal{H}(x^{i-1,j}) & j = 0 \quad \text{(encodeur)} \\ \mathcal{H}\left(\left[x^{i,k}\right]_{k=0}^{j-1}, \text{UpConv}(x^{i+1,j-1})\right) & j > 0 \end{cases} \tag{7.5}$$

où $\mathcal{H}$ est un bloc convolutif et $[\cdot]$ la concaténation. La supervision profonde (*deep supervision*) entraîne chaque sortie $\hat{y}^{(j)}$: $\mathcal{L} = \sum_{j=0}^{J-1} w_j \mathcal{L}^{(j)}$.

7.3 3D U-Net (Çiçek et al., 2016)

L'extension volumétrique remplace toutes les opérations 2D par leurs équivalents 3D pour les données volumétriques (IRM 3D, CT scans) :

Convolution 3D

$$Z[i,j,k] = \sum_{m,n,p} X[i+m, j+n, k+p] \cdot W[m,n,p] + b \tag{7.6}$$

Coût mémoire : $\mathcal{O}(C_{\text{in}} \cdot C_{\text{out}} \cdot k^3)$ vs. $\mathcal{O}(C_{\text{in}} \cdot C_{\text{out}} \cdot k^2)$ en 2D — multiplication par k du nombre de paramètres.

7.4 Swin-UNet (Cao et al., 2021)

Swin-UNet remplace les blocs convolutifs par des **Shifted Window Transformers**, introduisant l'auto-attention globale :

Window Self-Attention (WSA)

$$\text{Attention}(Q,K,V) = \text{softmax}\left(\frac{QK^\top}{\sqrt{d_k}} + B\right) V \tag{7.7}$$

$$Q = XW_Q, \quad K = XW_K, \quad V = XW_V \tag{7.8}$$

où B est un biais de position relatif appris dans chaque fenêtre de taille $M \times M$. La complexité est $\mathcal{O}(M^2 HW)$ vs. $\mathcal{O}((HW)^2)$ pour l'attention globale.

7.5 Résumé comparatif des variantes

Table 7.1. Comparaison des principales variantes de U-Net

Architecture	Innovation	Params	mIoU↑	Année
U-Net	Skip connections, enc-dec	31M	Référence	2015
SegNet	Indices de pooling	29M	–	2015
Attention U-Net	Attention gates	35M	+2%	2018
U-Net++	Dense skip + deep sup.	47M	+3%	2019
3D U-Net	Volumétrique	19M*	+5%*	2016
nnU-Net	Auto-config.	Var.	SOTA	2021
Swin-UNet	Transformers hiérar.	27M	+4%	2021
TransUNet	CNN + ViT hybride	93M	+5%	2021

* Sur données 3D. Gains indicatifs sur benchmarks médicaux.

8

Applications et État de l'Art

8.1 Segmentation médicale

U-NET s'est imposé comme l'architecture de référence en imagerie médicale. L'article original a été cité plus de **60 000 fois** (Google Scholar, 2024), en faisant l'un des articles les plus influents de l'histoire du deep learning.

Table 8.1. Benchmarks U-Net sur jeux de données médicaux

Dataset	Tâche	Dice (%)	Architecture
ISIC 2018	Lésions cutanées	89.2	Attention U-Net
BraTS 2021	Tumeurs cérébrales (IRM)	91.4	nnU-Net 3D
PASCAL VOC	Segmentation naturelle	82.1	DeepLab v3+
CityScapes	Scènes urbaines	83.5	HRNet
LiTS	Foie + tumeurs (CT)	96.1 / 74.3	nnU-Net
Retinal Vessels	Vaisseaux rétiniens	82.0	U-Net classique

8.2 Au-delà du médical : domaines d'application

1. **Télédétection et cartographie** : segmentation de bâtiments, routes, végétation dans les images satellites.

2. **Conduite autonome** : segmentation de la chaussée, piétons, véhicules (CityScapes, KITTI).
3. **Contrôle qualité industriel** : détection de défauts de surface par segmentation pixel à pixel.
4. **Agriculture de précision** : cartographie des cultures et détection de maladies sur images UAV.
5. **Océanographie** : suivi de la banquise, identification de zones coralliennes dans les images satellitaires.

9

Fondements Théoriques Profonds

9.1 Connexion avec la théorie de l'information

§ 9.1.1 Entropie croisée comme divergence KL

La perte d'entropie croisée peut s'interpréter comme la minimisation de la divergence de Kullback-Leibler entre la distribution cible p et la distribution prédite q_θ :

Interprétation information-théorique

$$\mathcal{L}_{\text{CE}} = -\mathbb{E}_{(x,y)\sim\mathcal{D}}\left[\log q_\theta(y|x)\right] \tag{9.1}$$

$$= \mathbb{E}\left[D_{\text{KL}}(p(\cdot|x) \parallel q_\theta(\cdot|x))\right] + H(p(\cdot|x)) \tag{9.2}$$

où $D_{\text{KL}}(p\|q) = \sum_y p(y)\log\frac{p(y)}{q(y)} \geq 0$ (inégalité de Gibbs). Minimiser la CE revient donc à minimiser la divergence KL entre vérité terrain et prédiction.

9.2 Lien avec les auto-encodeurs variationnels

L'architecture encodeur-décodeur de U-Net peut être reliée aux **auto-encodeurs** de la théorie de la représentation. La différence fondamentale est que :

- Un auto-encodeur standard minimise $\|x - \hat{x}\|^2$ (reconstruction fidèle).
- U-Net minimise une perte de segmentation $\mathcal{L}(y, f_\theta(x))$ (prédiction supervisée).

- Les skip connections rompent le goulot d'information : l'encodeur n'est pas contraint à tout compresser.

9.3 Théorème d'approximation universel et profondeur

Théorème d'approximation universelle (Cybenko, 1989 — extension CNN)

Pour tout $\varepsilon > 0$ et toute fonction mesurable bornée $f^* : [0,1]^{H\times W} \to [0,1]^{H\times W}$, il existe un CNN f_θ avec un nombre fini de paramètres θ tel que :

$$\sup_{x\in[0,1]^{H\times W}} \|f_\theta(x) - f^*(x)\|_\infty < \varepsilon \tag{9.3}$$

La profondeur confère une **efficacité exponentielle** : certaines fonctions nécessitent un réseau profond polynomial en n là où un réseau superficiel demanderait un nombre exponentiel de neurones.

9.4 Interprétabilité : Grad-CAM en segmentation

Les **cartes d'activation pondérées par le gradient** (Gradient-weighted Class Activation Maps, Grad-CAM) permettent de visualiser quelles régions de l'image influencent la décision du modèle :

Grad-CAM adapté à la segmentation

$$\alpha_k^c = \frac{1}{Z}\sum_{i,j}\frac{\partial S^c}{\partial A_{ij}^k} \qquad \text{(importance du canal } k \text{ pour la classe } c\text{)} \tag{9.4}$$

$$L^c_{\text{Grad-CAM}} = \text{ReLU}\left(\sum_k \alpha_k^c A^k\right) \tag{9.5}$$

où $S^c = \sum_{i,j} \hat{p}_{ij}^{(c)}$ est le score total de la classe c et A^k la carte d'activation du canal k.

Conclusion et Perspectives

U-NET incarne une solution élégante à un problème fondamental de la vision par ordinateur : comment préserver simultanément le contexte sémantique global et la précision spatiale locale ? La réponse — les *skip connections* — est devenue un paradigme architectural universel, présent dans ResNet (connexions résiduelles), DenseNet (connexions denses), et les architectures Transformer modernes.

Les fondements mathématiques présentés dans ce document — convolution, normalisation, fonctions d'activation, pertes de segmentation, rétropropagation — constituent le socle technique indispensable pour maîtriser et adapter U-Net à tout contexte applicatif.

Les perspectives actuelles s'orientent vers : **(i)** l'hybridation CNN-Transformer (TransUNet, Swin-UNet) combinant localité convolutive et globalité attentionnelle ; **(ii)** les méthodes few-shot et zero-shot pour les pathologies rares ; **(iii)** l'incertitude quantifiée (MC Dropout, Deep Ensembles) pour la sécurité clinique ; **(iv)** la distillation de modèles pour le déploiement embarqué.

Références Bibliographiques

Référence	Citation complète
Ronneberger 2015	Ronneberger O., Fischer P., Brox T. *U-Net: Convolutional Networks for Biomedical Image Segmentation*. MICCAI 2015.
Long 2015	Long J., Shelhamer E., Darrell T. *Fully Convolutional Networks for Semantic Segmentation*. CVPR 2015.
Ioffe 2015	Ioffe S., Szegedy C. *Batch Normalization: Accelerating Deep Network Training*. ICML 2015.
Kingma 2015	Kingma D., Ba J. *Adam: A Method for Stochastic Optimization*. ICLR 2015.
Oktay 2018	Oktay O. et al. *Attention U-Net: Learning Where to Look for the Pancreas*. MIDL 2018.
Zhou 2019	Zhou Z. et al. *UNet++: A Nested U-Net Architecture*. DLMIA 2018 / TMI 2019.
Cicek 2016	Çiçek Ö. et al. *3D U-Net: Learning Dense Volumetric Segmentation*. MICCAI 2016.
Lin 2017	Lin T.-Y. et al. *Focal Loss for Dense Object Detection*. ICCV 2017.
Cao 2021	Cao H. et al. *Swin-UNet: Unet-like Pure Transformer for Medical Segmentation*. ECCV 2022.
Isensee 2021	Isensee F. et al. *nnU-Net: a self-configuring method for deep learning-based biomedical image segmentation*. Nature Methods, 2021.
Cybenko 1989	Cybenko G. *Approximation by superpositions of a sigmoidal function*. Math. Control Signals Systems, 1989.
Vaswani 2017	Vaswani A. et al. *Attention Is All You Need*. NeurIPS 2017.

U-Net — Fondements Théoriques & Mathématiques

Segmentation Sémantique par Deep Learning

Groupe Deep Learning — AS3 2025–2026

Ndeye Khar SALL · Kouami Emmanuel DOSSEKOU

Awa GUEYE · Fatou Soumaya WADE

ENSAE · Dakar, 2026

Référence principale : Ronneberger, Fischer & Brox (MICCAI 2015)

Document produit sous LaTeX · Formules complètes · +60 équations